Analyse du marché de l'assurance habitation : document technique

Livrable 1 · Zid Ahmed Moundji

1. Contexte et jeux de données

Une entreprise d'assurance souhaite mieux accompagner ses clients en analysant le marché des assurances habitation. Deux fichiers CSV (séparateur « ; », encodage UTF-8) sont exploités.

Fichier	Lignes	Colonnes	Contenu
Contrat.csv	30 335	14	Contrats clients : adresse, surface, type de logement, formule, cotisation
Region.csv	38 916	8	Référentiel géographique : commune, département, académie, région (source : data.gouv.fr)

Le lien entre les deux fichiers est la colonne Code_dep_code_commune (concaténation du code département et du code commune). Elle est clé primaire de Region et clé étrangère de Contrat.

2. Exploration des types de données

Chaque colonne a été parcourue (filtres, valeurs distinctes, longueur maximale) afin de choisir un type et une taille. Voici le dictionnaire complété.

	Nom des colonnes	Type de données	Taille	Clé	Description
CONTRAT.CSV	Contrat_ID	INT		Clé primaire	Id unique pour les contrats
	No_voie	INT			Numéro dans la voie pour l'adresse du logement assuré
	B_T_Q	CHAR	1		Indicateur éventuel de répétition pour l'adresse du logement assuré sur un caractère
	Type_de_voie	VARCHAR	10		Type de voie pour l'adresse du logement assuré: rue, av (Avenue), rte (Route), ...
	Voie	VARCHAR	50		Libellé de la voie pour l'adresse du logement assuré
	Code_dep_code_commune	VARCHAR	6	Clé secondaire	Concaténation du code département et code commune pour avoir une clé unique
	Code_postal	VARCHAR	5		Code postal pour l'adresse du logement assuré
	Surface	INT			Superficie du logement assuré en m²
	Type_local	VARCHAR	20		Nature ou type de logement assuré
	Occupation	VARCHAR	64		Statut d'occupation du logement par l'assuré
	Type_contrat	VARCHAR	25		Usage du logement couvert par le contrat
	Formule	VARCHAR	30		Type de formule
	Valeur_declaree_biens	VARCHAR	25		Tranche de valeur financière déclarée du mobilier et des biens assurés
	Prix_cotisation_mensuel	INT			Montant de la cotisation mensuelle payée par le client en euros
REGION.CSV	Code_dep_code_commune	VARCHAR	6	Clé primaire	Concaténation du code département et code commune pour avoir une clé unique
	reg_code	VARCHAR	2		Code de la région
	reg_nom	VARCHAR	50		Nom de la région
	aca_nom	VARCHAR	30		Nom de l'académie
	dep_nom	VARCHAR	50		Nom du département
	com_nom_maj_court	VARCHAR	45		Nom de la commune
	dep_code	CHAR	3		Code du département
	dep_nom_num	VARCHAR	55		Numéro et nom du département

Contrat_ID, No_voie, Surface et Prix_cotisation_mensuel sont numériques (INT). Les codes (code postal, code commune, code région, code département) restent en texte pour conserver les zéros initiaux et les valeurs comme « 2A ».

Variable	Modalités observées
Type_local	Appartement, Maison
Occupation	Locataire, Proprietaire
Type_contrat	Residence principale, Residence secondaire, Mise en location
Formule	Classique, Integral
Valeur_declaree_biens	0-25000, 25000-50000, 50000-100000, 100000+
B_T_Q	Une lettre (A, B, T…), vide si non renseigné

3. Schéma relationnel modifié

Le schéma de départ a été complété dans SQL Power Architect : ajout des colonnes manquantes, modification des types et ajout des contraintes (NOT NULL, clé primaire, clé étrangère). Une commune (Region) peut être rattachée à plusieurs contrats.

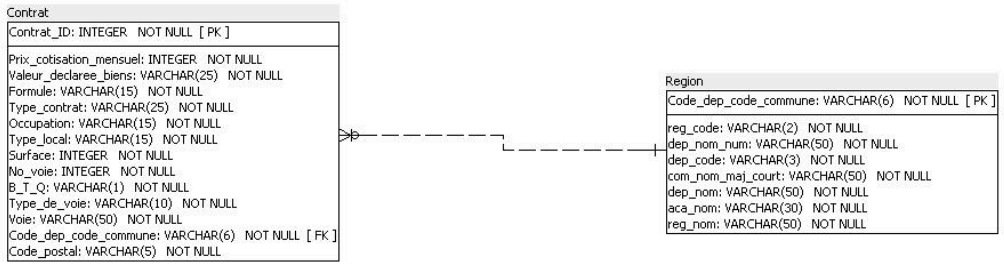


Table	Clé primaire	Clé étrangère
Region	Code_dep_code_commune	—
Contrat	Contrat_ID	Code_dep_code_commune → Region

4. Code SQL de création des tables

Script généré par SQL Power Architect : tables Region et Contrat, puis contrainte de clé étrangère.

```
CREATE TABLE Region (
    Code_dep_code_commune VARCHAR(6) NOT NULL,
    reg_code VARCHAR(2) NOT NULL,
    dep_nom_num VARCHAR(50) NOT NULL,
    dep_code VARCHAR(3) NOT NULL,
    com_nom_maj_court VARCHAR(50) NOT NULL,
    dep_nom VARCHAR(50) NOT NULL,
    aca_nom VARCHAR(30) NOT NULL,
    reg_nom VARCHAR(50) NOT NULL,
    CONSTRAINT Region_pk PRIMARY KEY (Code_dep_code_commune)
);

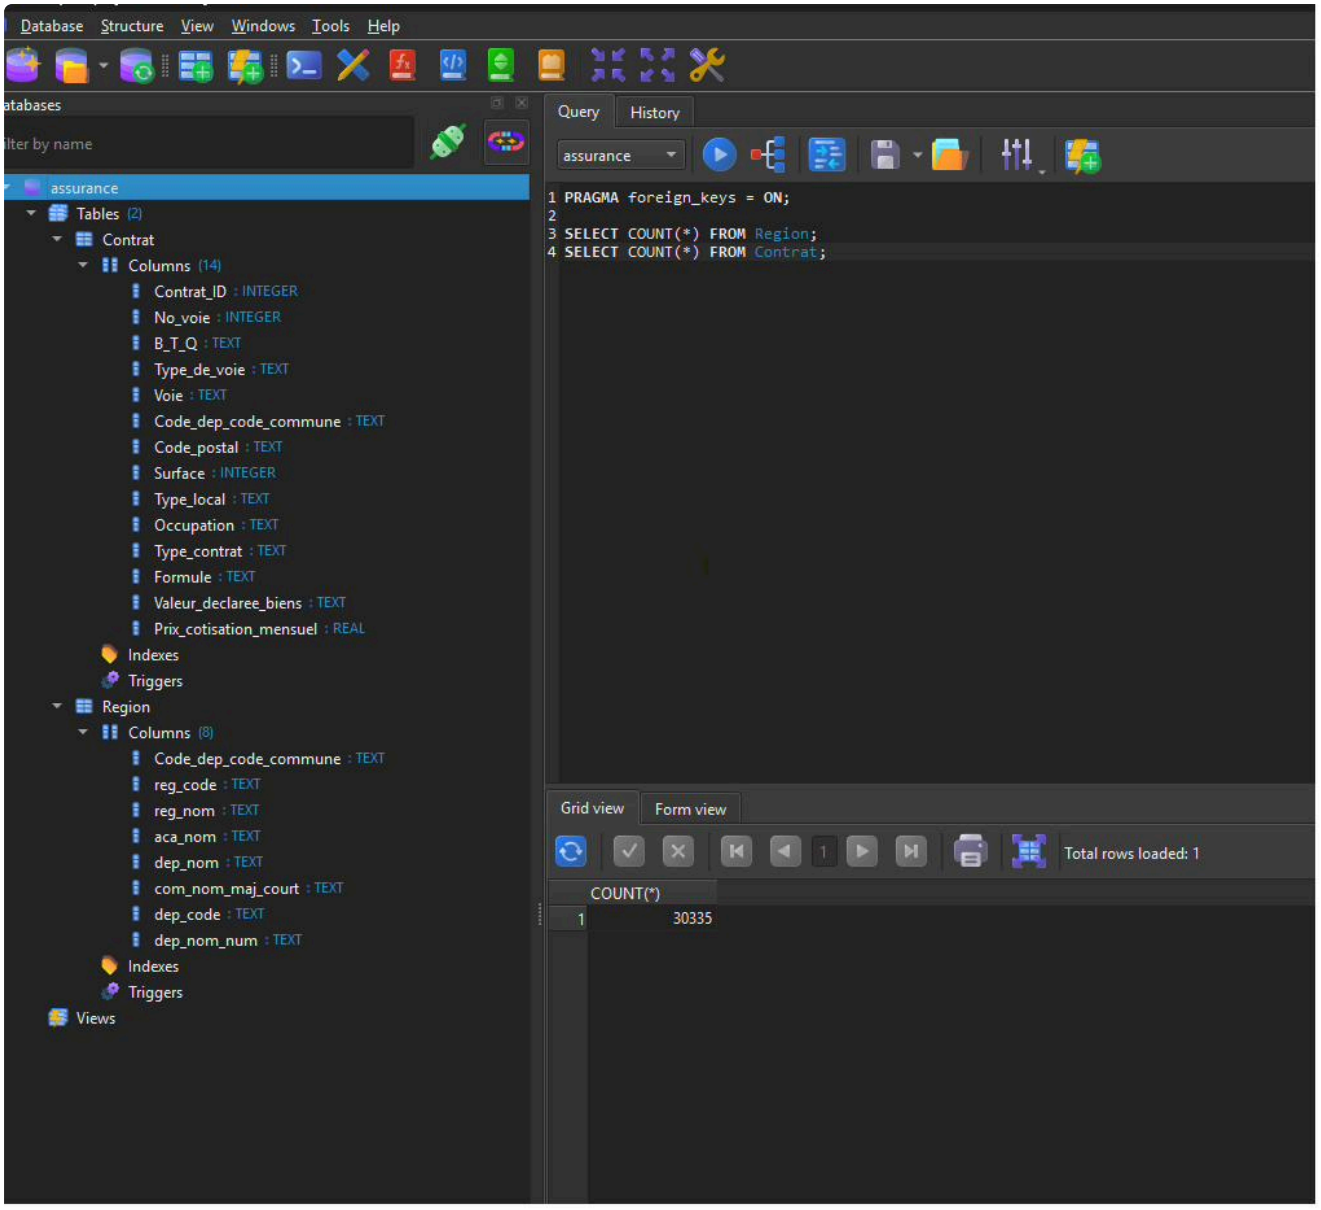
CREATE TABLE Contrat (
    Contrat_ID INTEGER NOT NULL,
    Prix_cotisation_mensuel INTEGER NOT NULL,
    Valeur_declaree_biens VARCHAR(25) NOT NULL,
    Formule VARCHAR(15) NOT NULL,
    Type_contrat VARCHAR(25) NOT NULL,
    Occupation VARCHAR(15) NOT NULL,
    Type_local VARCHAR(15) NOT NULL,
    Surface INTEGER NOT NULL,
```

```
    No_voie INTEGER NOT NULL,
    B_T_Q VARCHAR(1) NOT NULL,
    Type_de_voie VARCHAR(10) NOT NULL,
    Voie VARCHAR(50) NOT NULL,
    Code_dep_code_commune VARCHAR(6) NOT NULL,
    Code_postal VARCHAR(5) NOT NULL,
    CONSTRAINT Contrat_pk PRIMARY KEY (Contrat_ID)
);

ALTER TABLE Contrat ADD CONSTRAINT Region_Contrat_fk
FOREIGN KEY (Code_dep_code_commune)
REFERENCES Region (Code_dep_code_commune)
ON DELETE NO ACTION
ON UPDATE NO ACTION
NOT DEFERRABLE;
```

5. Base de données chargée (SQLite)

Le SGBD retenu est SQLite (et non MySQL), consulté avec DB Browser for SQLite. Le script généré par SQL Power Architect a donc été adapté : SQLite applique une affinité de types (TEXT, INTEGER, REAL) et ne contraint pas strictement la taille des VARCHAR. Les tables Contrat et Region ont été créées dans la base « assurance », puis alimentées avec les deux CSV. L'option PRAGMA foreign_keys = ON active le contrôle de la clé étrangère.



La table Contrat contient 30 335 lignes, soit exactement le nombre de lignes de Contrat.csv. Le fichier source Region.csv compte 38 916 lignes. Neuf contrats (communes 97434, 97460 et 97470, à La Réunion) n'ont aucune correspondance dans Region : ils ne peuvent pas être rattachés par la clé étrangère et sont exclus des requêtes qui utilisent un INNER JOIN.

6. Points d'attention

- Type de la cotisation : INTEGER dans le script, REAL dans DB4S, car SQLite applique une affinité de type à l'import. Les valeurs du CSV sont entières, le résultat des requêtes n'est pas modifié.
- Tailles de colonnes : script et dictionnaire diffèrent légèrement (Formule : 15 contre 30). Les longueurs maximales observées (Formule : 9, Occupation : 12, Type_local : 11) tiennent dans les deux cas.

- Régions : le référentiel compte 19 régions, dont 16 ont au moins un contrat.
- Contrats sans commune : 9 contrats de La Réunion (codes 97434, 97460, 97470) n'existent pas dans Region. Un INNER JOIN les exclut, d'où un total de 30 326 contrats dans l'analyse 12 au lieu de 30 335. Un LEFT JOIN les conserverait avec des valeurs régionales vides.
- Valeurs non renseignées : No_voie (122), B_T_Q (28 422) et Type_de_voie (771) sont vides dans le fichier source. Il s'agit de chaînes vides et non de NULL, la contrainte NOT NULL du script n'est donc pas violée techniquement. B_T_Q est vide pour toutes les adresses sans bis, ter ou quater.
- Zéros initiaux perdus : 1 664 codes postaux n'ont que 4 chiffres (1370 au lieu de 01370) et dep_code vaut « 1 » et non « 01 ». Les analyses 1, 8 et 9 ne sont pas touchées (codes 92100, 71 et 75).
- Surfaces atypiques : 24 contrats ont une surface de 0 m² et la surface maximale atteint 815 m². Ces valeurs devraient être vérifiées avant toute exploitation statistique.